


Rêver pour mieux mémoriser : optimisation mémoire dans les réseaux de Hopfield

Jilian Lubrat — SI5 IAID 2025/2026

Encadrant : Étienne Lozes — I3S, équipe SCALE


Introduction

Les réseaux de Hopfield sont des mémoires adressables par le contenu : à partir d'une entrée bruitée, ils convergent vers un motif stocké en minimisant une énergie.



Mémoire associative : rappel d'un motif bruité

Exemple de rappel dans un réseau de Hopfield : une entrée fortement bruitée (gauche) converge vers un motif mémorisé après relaxation (droite).



Les réseaux classiques ont toutefois une capacité limitée et génèrent des états parasites, surtout lorsque les motifs sont corrélés.

Ce projet étudie expérimentalement deux approches pour améliorer ces performances : des mécanismes inspirés du rêve et les réseaux de Hopfield modernes.

L'objectif est aussi de visualiser et de caractériser le paysage énergétique (évolution de l'énergie, bassins d'attraction) afin de relier les observations aux phénomènes de capacité, robustesse au bruit et apparition d'états parasites.

Cadre théorique : les réseaux classiques et modernes

Réseau de Hopfield classique

La dynamique du réseau est vue comme une descente dans un paysage énergétique : stocker des motifs revient à creuser des puits d'énergie, et le rappel correspond à la convergence vers un minimum. Permet de stocker de manière stable environ $0,14 * N$ motifs non corrélés.

- Dynamique : $X_i(t+1) = \text{sign}(\sum_{j \neq i} W_{ij} X_j(t))$
- Énergie : $E = -\frac{1}{2} \sum_{i,j} W_{ij} X_i X_j$
- Apprentissage (règle de Hebb) :

$$W_{ij} = \frac{1}{N} \sum_{p=1}^P X_i^{(p)} X_j^{(p)}, W_{ii} = 0$$

Réseau de Hopfield Moderne

L'énergie est modifiée pour utiliser une fonction F (polynomiale ou exponentielle), ce qui crée des bassins d'attraction plus sélectifs, augmentant la capacité de stockage :

$$F(x) = x^n \Rightarrow P_{\max} \approx \alpha_n N^{n-1} \quad F(x) = e^x \Rightarrow P_{\max} \approx 2^{N/2}$$

- Énergie : $E = -\sum_{\mu=1}^P \sum_i F(\xi_i^\mu X_i)$
- Dynamique : $X_i^{(t+1)} = \text{Sign} \left[\sum_{\mu=1}^P \left(F(\xi_i^\mu + \sum_{j \neq i} \xi_j^\mu X_j^{(t)}) - F(-\xi_i^\mu + \sum_{j \neq i} \xi_j^\mu X_j^{(t)}) \right) \right]$

Représentation du paysage énergétique





Illustration d'un paysage énergétique : à partir d'un état initial, la dynamique converge vers un attracteur (motif mémorisé), mais peut aussi être piégée par un minimum local correspondant à un état parasite.

Méthode améliorant la capacité des réseaux classiques

Unlearning

À forte charge, le réseau converge souvent vers des états parasites, l'unlearning les pénalise en augmentant leur énergie lissant les minima indésirables. Améliore la capacité jusqu'à $0,58 * N$ dans les mêmes conditions que le réseau classique.

Effet de l'unlearning sur le paysage énergétique




La mise à jour anti-Hebb augmente l'énergie des points fixes indésirables, lissant ainsi le paysage énergétique et réduisant la profondeur des minima parasites.

Matrice projecteur

Pour s'affranchir des corrélations, la matrice projecteur force les motifs à être des points fixes exacts. W est construite comme un projecteur sur l'espace engendré par les motifs. Améliore la capacité jusqu'à $1 * N$ si les motifs sont linéairement indépendants.

Matrice projecteur : interprétation géométrique



W agit comme un projecteur sur l'espace des motifs : l'état du réseau est ramené vers ce sous-espace, ce qui favorise la convergence vers un motif mémorisé.

Notations utilisées

- N : nombre de neurones
- $X \in \{-1, +1\}^N$: état du réseau
- $\{\xi^\mu\}_{\mu=1..P}$: motifs à mémoriser
- $W \in \mathbb{R}^{N \times N}$: matrice des poids

Étude de l'impact du rêve

Objectif

Mesurer la capacité effective : combien de motifs stockés sont rappelés exactement, et l'impact des méthodes de "rêve".

Données


- ImageNet 16x16 (binaire, 1 image/classe)
- Décorrélé : images aléatoires binaires

Protocole


- Entraîner le réseau à stocker P motifs
- Appliquer (ou non) le rêve
- Initialiser avec chaque motif d'entraînement
- L'erreur est le pourcentage de motifs non rappelés exactement

Stabilité du rappel selon la charge mémoire

ImageNet 16 x 16



Dataset non corrélé (images aléatoires)



Taux d'erreur de rappel (motifs non récupérés exactement) en fonction du nombre de motifs stockés P , pour trois méthodes (réseau classique, unlearning, matrice projecteur). Comparaison entre un dataset corrélé (ImageNet 16x16) et un dataset décorrélé (images aléatoires), montrant l'impact des corrélations sur la stabilité et la capacité de stockage.

Résultats

- Données corrélées (ImageNet 16x16) :** Les corrélations entraînent de fortes interférences : la capacité reste, dans tous les cas, bien inférieure aux limites théoriques. L'unlearning limite seulement la dégradation sans gain concret. La matrice projecteur n'atteint pas $P \approx N$, car les motifs ne sont pas linéairement indépendants, mais fournit tout de même une nette amélioration.
- Données décorrélées (motifs aléatoires) :** Dans ce cas favorable, l'unlearning retrouve la capacité attendue $\approx 0,58N$ (≈ 150 motifs pour $N = 256$), et la matrice projecteur également $\approx N$ (≈ 256 motifs pour $N = 256$).

Expérimentations sur l'énergie des réseaux modernes

Objectif

Étudier l'effet de la fonction polynomiale ou exponentielle de l'énergie sur :

- la robustesse au bruit
- la dynamique de convergence
- la forme du paysage énergétique

Données et paramètres

Jeu de motifs aléatoires afin d'isoler l'effet du degré du polynôme. Pour l'étude des profils énergétiques, les réseaux ne sont pas saturés.

Protocoles

Robustesse au bruit

- Bruit contrôlé : inversion exacte de k pixels ($k \leq 128$)
- Convergence asynchrone, succès si rappel exact
- Répété pour différents niveaux de bruit et nombres de motifs stockés


Profil énergétique (visualisation)

- Bruit fixé (ex. 100 pixels inversés)
- Enregistrement de l'énergie à chaque mise à jour
- Analyse de E en de la distance de Hamming au motif cible


Résultats

Robustesse au bruit : Tant que la capacité n'est pas saturée, le seuil de bruit corrigible reste du même ordre, quelle que soit la puissance. En augmentant le nombre de motifs, le réseau classique devient rapidement instable (cf. stabilité des réseaux classiques). Pour les réseaux modernes, on voit une baisse du bruit corrigible ($\approx 100 \rightarrow \approx 90$ pixels) avec l'augmentation des motifs sauvegardé, cohérent avec l'idée théorique de bassins d'attraction qui se rétrécissent à l'approche de la saturation.


Paysage énergétique : Quand le degré du polynôme augmente, le paysage devient plus sélectif : on observe un plateau puis une chute rapide vers le minimum quand l'état est proche du motif, cela limite le chevauchement entre bassins et aide à réduire les états parasites.



Trajectoires : L'énergie est fortement liée à la distance de Hamming au motif (trajectoires quasi superposées), sauf en cas de convergence vers un état parasite ou un autre motif.



Robustesse au bruit



Nombre de motifs sauvegardés

Cartes de chaleur de la fraction de motifs instables (%) selon le nombre de motifs sauvegardés (axe x) et le bruit (pixels inversés, axe y).
Haut : réseau classique ($F(x) = x^2$).
Bas : réseau moderne ($F(x) = x^{10}$), la zone "calculée" indique le domaine effectivement évalué.

Trajectoires de relaxation dans le paysage énergétique en fonction de la distance de Hamming au motif de référence, pour différents niveaux de bruit initial. Comparaison entre modèle classique (gauche) et modèle moderne (droite).

