

PER2025–023 – Rêver pour mieux mémoriser : optimisation mémoire dans les réseaux de Hopfield

Analyse expérimentale du paysage énergétique

Jilian Lubrat
SI5, 2025–2026

Polytech Nice Sophia, Université Côte d'Azur
jilian.lubrat@etu.unice.fr

Encadrant : Étienne Lozes

Résumé Les réseaux de Hopfield constituent un type de mémoire associative dont la dynamique de relaxation peut être interprétée comme une descente dans un paysage énergétique. Cependant, les réseaux dits classiques (historiquement les premiers) souffrent d'une capacité de stockage limitée et de la présence d'états parasites, en particulier lorsque les motifs sont corrélés. Ce rapport est structuré en deux temps : (I) une revue détaillée de l'état de l'art couvrant les réseaux de Hopfield classiques, les mécanismes inspirés du rêve (unlearning et matrice projecteur) et les réseaux modernes ; puis (II) une étude expérimentale centrée sur l'augmentation de la capacité des réseaux classiques (via le rêve) ainsi que sur l'influence du degré du polynôme dans les réseaux de Hopfield modernes, et son impact sur la robustesse au bruit et la topologie du paysage énergétique.

Keywords: réseau de Hopfield · réseau de Hopfield moderne · paysage énergétique · unlearning · matrice projecteur

Table des matières

Liste des notations	3
1 Introduction	4
2 État de l'art	4
2.1 Les réseaux de Hopfield classiques	4
Lien avec la physique statistique	4
Dynamique de relaxation et paysage énergétique	5
Apprentissage hebbien	6
Limites : capacité, phases et corrélations	7
2.2 Le <i>rêve</i> dans les réseaux de Hopfield classiques	8
Unlearning	8
Matrice projecteur	8
2.3 Les réseaux de Hopfield modernes	9
Définition moderne	9
Amélioration de la capacité de stockage	10
3 Étude expérimentale	11
3.1 Objectifs	11
3.2 Étude de l'augmentation de la capacité de stockage via le rêve	
dans le réseau classique	11
But de l'expérience	11
Méthodes comparées	11
Protocole utilisé	11
Hyperparamètres et dataset	11
Résultats et analyse	13
3.3 Étude de l'influence de la modification de l'énergie dans les	
réseaux de Hopfield modernes	13
But de l'expérience	13
Modèles comparés	13
Protocole utilisé	14
Hyperparamètres et dataset	14
Résultats et analyse	14
3.4 Synthèse	17
4 Discussion	18
5 Conclusion	19
Références	20
Ressources	20

Liste des notations

N : Nombre de neurones dans le réseau

P : Nombre de motifs mémorisés

α : Charge du réseau, $\alpha = P/N$

W : Matrice des poids synaptiques associée au réseau, avec $W \in \mathbb{R}^{N \times N}$,
 $W_{ii} = 0$ et W_{ij} le poids de la connexion entre les neurones i et j

$X(t)$: Vecteur d'état du réseau à l'instant t , avec $X(t) \in \{-1, +1\}^N$

$\{\xi^\mu\}_{\mu=1}^P$: Ensemble des P motifs (*patterns*) à mémoriser

1 Introduction

Les réseaux de Hopfield sont des réseaux de neurones qui implémentent **une mémoire adressable par le contenu** : une entrée partielle ou bruitée peut être rappelée en convergeant vers un attracteur correspondant à un motif mémorisé [6]. L'innovation majeure du modèle est son analogie avec la physique statistique : la dynamique du réseau peut être interprétée comme la relaxation d'un verre de spins, ce qui fournit une lecture énergétique (énergie de Lyapunov) du processus d'évolution du réseau [1,12,2].

Cependant, les réseaux dits classiques souffrent de deux limites importantes : une capacité de stockage relativement faible et l'apparition d'états parasites, phénomènes accentués lorsque les motifs sont corrélés. Plusieurs mécanismes ont été proposés pour atténuer ces effets, notamment des procédures inspirées du *rêve* (par exemple l'unlearning) ainsi que des règles de type projecteur, et plus récemment des réseaux de Hopfield modernes où la fonction d'énergie dépend d'une *puissance*.

L'objectif de ce travail est d'apporter une **analyse expérimentale** de ces résultats théoriques afin de mieux caractériser (i) la **capacité de stockage** et (ii) la **robustesse au bruit** lors du rappel. Nous présentons d'abord une revue de l'état de l'art (Section 2), puis nous détaillons une première étude expérimentale sur les mécanismes de rêve, et une seconde visant à visualiser et quantifier l'effet du degré du polynôme dans l'énergie des réseaux de Hopfield modernes sur la robustesse au bruit et la géométrie des bassins d'attraction (Section 3).

2 État de l'art

2.1 Les réseaux de Hopfield classiques

Introduits par John Hopfield en 1982 [6], ces réseaux proposent une architecture de mémoire adressable par le contenu (CAM). Contrairement à une mémoire classique (RAM) où l'accès se fait par adresse, la CAM permet de retrouver une information complète à partir d'un fragment ou d'une version bruitée, mimant des capacités de reconstruction de la mémoire biologique.

Lien avec la physique statistique. L'innovation majeure de Hopfield réside dans l'analogie qu'il établit entre les réseaux de neurones et la physique statistique, en particulier celle des verres de spin. Ces derniers sont des alliages magnétiques contenant une faible proportion d'impuretés réparties aléatoirement dans le métal. Ces impuretés peuvent être modélisées par le modèle d'Ising, qui permet de décrire à la fois leur spin, une variable pouvant prendre deux états discrets, et les interactions entre ces spins [12]. Hopfield transpose ce fonctionnement en remplaçant les impuretés par des neurones, où les deux états modélisent l'activation ou le repos. Bien qu'il ait initialement formulé son modèle avec des neurones binaires $\{0, 1\}$, il est courant dans la littérature d'utiliser le formalisme d'Ising $\{-1, +1\}$ [1,2,9], que nous adoptons ici.




FIGURE 1. Architecture d'un réseau de Hopfield suivant le modèle d'Ising (noir : -1 , blanc : $+1$).

Structurellement, le réseau forme un graphe **complet**, **pondéré** et **non orienté**, comme illustré en Fig. 1 : chaque neurone est connecté à tous les autres, sauf à lui-même, via des connexions synaptiques symétriques dont les poids quantifient la force des interactions. Le système est défini par un état initial $X(t)$ et une matrice de poids symétrique à diagonale nulle W , qui représente l'ensemble des poids entre les neurones.

Dynamique de relaxation et paysage énergétique. Le fonctionnement du réseau est un processus de recherche d'un état stable, basé sur la dynamique suivante [6] :

- (i) on initialise le réseau dans un état quelconque $X(t)$ (par exemple une version bruitée d'un motif)
- (ii) on le laisse évoluer : les neurones interagissent afin de réduire les frustrations locales et guider le système vers un état stable
- (iii) le réseau converge vers un attracteur correspondant à un motif stocké (ou, dans certains cas, vers un état parasite)

Durant cette évolution du système l'état du neurone i est mis à jour en suivant la règle :

$$X_i(t+1) = \rho\left(\sum_{j \neq i} W_{ij} X_j(t)\right), \quad (1)$$

avec ρ la fonction d'activation des neurones, ici $\rho = \text{sign}(\cdot)$ pour respecter le formalisme d'Ising.

Pour ce qui est de l'évolution du système, on peut distinguer deux catégories [2] :

- **Évolution Synchrone** : Tous les neurones sont mis à jour simultanément en fonction de l'état du réseau à l'instant t . Bien que parallélisable, cette dynamique peut ne pas converger vers un état stable en engendrant des oscillations cycliques entre deux états différents.
- **Évolution asynchrone** : Un seul neurone est sélectionné (aléatoirement ou séquentiellement) pour être mis à jour à chaque pas de temps. C'est ce mode qui garantit la convergence vers un état stable dans le modèle de Hopfield original [6].

Du fait de l'analogie avec le système des verres de spin de la physique statistique apportée par Hopfield, on peut assimiler l'évolution du réseau à la relaxation d'un système physique vers un état de minimum local d'énergie. Cette fonction d'énergie ou fonction de Lyapunov est définie comme étant [6] :

$$E(\mathbf{X}) = -\frac{1}{2} \sum_{i,j} W_{ij} X_i X_j. \quad (2)$$

Les états stables du réseau correspondent à des minima locaux ou globaux de E . Le rappel de mémoire peut se représenter comme la descente d'une bille dans le paysage énergétique jusqu'au fond du bassin d'attraction le plus proche comme l'illustre la Fig. 2.

Apprentissage hebbien. Dans ce contexte, l'apprentissage revient à sculpter le paysage énergétique en ajustant les poids synaptiques. Cela est fait en calculant les poids via la règle de Hebb, proposé par Donald Hebb en 1949, qui postule le renforcement de la connexion entre deux neurones lors d'une activation simultanée [5]. Dans le cadre des réseaux de Hopfield, pour stocker P motifs $\{\xi^\mu\}_{\mu=1}^P$, elle s'écrit :

$$W_{ij} = \frac{1}{N} \sum_{\mu=1}^P \xi_i^\mu \xi_j^\mu, \quad W_{ii} = 0. \quad (3)$$

On cherche donc à positionner les minima locaux (les "creux" du paysage) aux coordonnées exactes des motifs à mémoriser. Le processus de rappel de mémoire correspond alors physiquement à la "descente" d'une bille le long de ce paysage jusqu'au fond du bassin d'attraction le plus proche [6].




FIGURE 2. Illustration d'un paysage énergétique pour un réseau à cinq neurones, montrant une évolution possible du système depuis un état initial vers un état stable. Présente également les états parasites susceptibles d'apparaître.

Limites : capacité, phases et corrélations. Amit, Gutfreund et Sompolinsky [1] établissent une capacité de stockage typique d'environ $0.14N$ pour des motifs aléatoires, un ordre de grandeur déjà observé empiriquement par Hopfield [6]. En posant la charge α , leur analyse thermodynamique met en évidence trois régimes :

- $\alpha < 0.05$: les motifs stockés correspondent (quasi) parfaitement aux minima ; rappel quasi parfait ;
- $0.05 < \alpha < 0.14$: le réseau reste fonctionnel mais des états parasites (mélanges de motifs) apparaissent ;
- $\alpha > 0.14$: prolifération d'états parasites, paysage chaotique et mémorisation impossible.

De plus, cette limite théorique (environ $0.14N$) suppose que les motifs stockés soient décorrélés, i.e. (quasi) orthogonaux. Dans un cas plus réaliste, les motifs présentent souvent des corrélations (par exemple des images similaires), ce qui augmente l'interférence entre les souvenirs. Cette interférence favorise l'apparition d'états parasites (un exemple est illustré par le point vert sur la Fig. 2) et peut entraîner un effondrement de la capacité de stockage, bien en dessous de 0.14 fois le nombre de neurones. Ce phénomène a été formellement mis en évidence par Personnaz, Guyon et Dreyfus [10] ainsi que par Löwe [9], qui montrent que la règle de Hebb classique ne permet pas de garantir la stabilité des motifs lorsqu'ils sont corrélés. Autrement dit, les motifs d'entraînement ne correspondent pas nécessairement à des minima locaux (ni globaux) de la fonction d'énergie et ne représentent donc pas des états stables atteignables par la dynamique de convergence du réseau.

2.2 Le rêve dans les réseaux de Hopfield classiques

Une limitation majeure des réseaux classiques est leur faible capacité de stockage. Plusieurs méthodes ont été proposées pour optimiser la capacité tout en conservant la dynamique fondamentale du réseau.

Unlearning. Le mécanisme d'unlearning a été introduit dans ce contexte par Hopfield, Feinstein et Palmer [7], ils s'inspirent des travaux de Crick et Mitchison [3] sur le sommeil paradoxal, qui suggèrent que les rêves contribuent à éliminer des connexions parasites accumulées au cours de la journée. Cette idée de "nettoyage" est alors transposée au réseau de Hopfield sous la forme d'un mécanisme de désapprentissage.

L'analogie est la suivante : si la règle de Hebb standard permet de stocker des motifs en "creusant" des bassins d'attraction dans le paysage énergétique, l'unlearning agit à l'inverse. En appliquant une règle anti-Hebbienne, il vise à "lisser" le paysage en réduisant la profondeur des minima indésirables (souvent associés à des états parasites), tout en préservant autant que possible les attracteurs correspondant aux motifs d'intérêt.

Procédure (schéma) :

- Génération d'un état initial aléatoire $X(t)$;
- Convergence du réseau vers un état stable $X(t)$;
- Application de la mise à jour anti-Hebbienne avec un pas ε faible :

$$W_{ij} \leftarrow W_{ij} - \varepsilon X_i X_j; \quad (4)$$

- Itération répétée du processus.

L'unlearning exploite un effet statistique : à forte charge, les états parasites sont bien plus nombreux que les motifs mémorisés, si bien qu'une dynamique initialisée au hasard converge plus souvent vers un parasite que vers un souvenir. En pénalisant ces points fixes via une mise à jour anti-Hebbienne, on réduit principalement les minima indésirables.

Les hyperparamètres restent empiriques : Hopfield, Feinstein et Palmer recommandent un ε faible ($0.01 < \varepsilon < 0.1$) et un nombre d'itérations limité pour éviter d'éroder les souvenirs [7].

Dans le cas de motifs décorrélés, la capacité peut atteindre $\approx 0.58N$ [7], tandis que des corrélations fortes diminuent l'efficacité du désapprentissage.

Matrice projecteur. Contrairement à l'approche énergétique "constructive" de Hebb, la méthode de la *matrice projecteur* (ou règle de la pseudo-inverse) adopte un point de vue essentiellement algébrique.

L'ensemble des motifs d'entraînement $\{\xi^\mu\}_{\mu=1}^P$, potentiellement corrélés, est vu comme un ensemble de vecteurs définissant un même espace de représentation. L'objectif est alors de construire une matrice de poids qui se comporte comme un projecteur orthogonal sur cet espace, de sorte que les motifs mémorisés deviennent des points fixes exacts, même lorsqu'ils ne sont pas orthogonaux entre eux.

Personnaz, Guyon et Dreyfus [10] montrent que la règle de Hebb ne garantit pas la stabilité de motifs corrélés et proposent de calculer directement la matrice de poids comme le projecteur orthogonal :

$$W = A (A^\top A)^{-1} A^\top, \quad (5)$$

où A est une matrice dont les colonnes sont les motifs d'entraînement. Cette construction garantit que $W\xi^\mu = \xi^\mu$ pour tout μ , dès lors que les motifs sont linéairement indépendants. En contrepartie, elle nécessite l'inversion de $A^\top A$, ce qui devient coûteux lorsque P augmente et rend l'interprétation biologique moins immédiate.

Cependant Plakhov et Semenov [11] montrent qu'une procédure itérative assimilable au "rêve" peut faire converger la matrice de Hebb vers le projecteur :

- On construit W via Hebb en **conservant la diagonale**
- On initialise le réseau avec un motif aléatoire $X(t)$
- On calcule les champs locaux $h_i = \sum_{j=1}^N W_{ij} X_j$
- On modifie W via le calcul suivant :

$$W_{ij} \leftarrow W_{ij} - \frac{\varepsilon}{N} h_i h_j; \quad (6)$$

- On itère plusieurs fois

Lorsque le nombre d'itérations tend vers l'infini, W converge asymptotiquement vers la matrice projecteur [11]. La convergence est garantie si

$$\varepsilon < \frac{1}{\lambda_{\max}}, \quad (7)$$

où $\lambda_{\max}$ est la plus grande valeur propre de W initial.

Cette approche s'affranchit de l'orthogonalité mais requiert l'indépendance linéaire : au plus N motifs indépendants peuvent être stockés. Au-delà, le système dégénère, la matrice W converge vers la matrice identité, tout état devient stable et le réseau n'apprend plus.

Ainsi, avec cette méthode, la capacité maximale théorique du réseau est bornée par le nombre de neurones, soit N .

2.3 Les réseaux de Hopfield modernes

Les réseaux de Hopfield modernes visent à augmenter drastiquement la capacité de stockage. Nous avons vu que la limite standard est $\approx 0.14N$ et qu'elle peut être poussée jusqu'à N via la méthode de la matrice projecteur.

Définition moderne. Krotov et Hopfield [8] introduisent les réseaux de Hopfield modernes ou mémoires associatives denses. L'intuition est topologique : dans le modèle classique, les puits d'attraction sont trop larges, favorisant les mélanges de motifs et l'apparition d'états parasites. L'idée est de rendre les puits plus étroits et plus profonds autour des motifs.

Pour cela, ils redéfinissent la fonction d'énergie globale du système par :

$$E(\mathbf{X}) = - \sum_{\mu=1}^P \sum_{i=1}^N F(\xi_i^\mu X_i), \quad (8)$$

où F est une fonction de lissage, par exemple polynomiale $F(x) = x^n$ [8] ou exponentielle $F(x) = e^x$ [4].

De cette énergie, on obtient une règle de mise à jour pilotée par une différence d'énergie :

$$X_i^{(t+1)} = \text{sign} \left[\sum_{\mu=1}^P \left(F\left(\xi_i^\mu + \sum_{j \neq i} \xi_i^\mu X_j^{(t)}\right) - F\left(-\xi_i^\mu + \sum_{j \neq i} \xi_i^\mu X_j^{(t)}\right) \right) \right]. \quad (9)$$

Contrairement aux formulations précédentes où la mise à jour est exprimée directement en termes de champ local, la règle de mise à jour dans ce cadre peut être interprétée comme étant explicitement pilotée par la différence d'énergie. Concrètement, l'argument de la fonction signe correspond à la différence d'énergie entre l'état où le neurone est actif (+1) et l'état où il est inactif (-1), le reste du réseau étant maintenu figé. Le système met ainsi à jour chaque unité de manière à garantir une diminution (ou, au minimum, à ne pas augmenter) l'énergie globale de la configuration.

Il est également intéressant de noter que le réseau de Hopfield classique apparaît comme un cas particulier de ce formalisme. En choisissant la fonction $F(x) = x^2$, on retrouve les équations standard, à une constante de normalisation près (la matrice de poids correspondant alors à une version non normalisée par le nombre de neurones). Les réseaux de Hopfield modernes généralisent donc le fonctionnement des réseaux classiques tout en offrant une flexibilité supplémentaire via le choix de la fonction F .

Amélioration de la capacité de stockage. Pour une interaction polynomiale de degré n , une loi typique est [8,2] :

$$P_{\max} \approx \alpha_n N^{n-1}, \quad (10)$$

où α_n dépend de n (avec $\alpha_2 \simeq 0.14$). Bien que α_n diminue avec n , le terme N^{n-1} croît fortement, ce qui explique l'augmentation de la capacité [8].

Avec une interaction exponentielle, Demircigil et al. montrent une capacité exponentielle, de l'ordre [4] :

$$P_{\max} \approx 2^{N/2}. \quad (11)$$

Cette capacité s'accompagne toutefois d'une contrepartie théorique majeure : lorsque le nombre de motifs stockés s'approche de cette limite exponentielle, le rayon des bassins d'attraction tend vers 0, ce qui annulerait la capacité de correction d'erreur [4,2]. Cette prédiction d'« effondrement des bassins » à saturation motive notre étude expérimentale (Section 3), où nous évaluerons la robustesse effective du réseau dans un régime de charge élevée comparé aux réseaux classiques mais non saturée.

3 Étude expérimentale

3.1 Objectifs

Cette partie vise deux objectifs complémentaires :

- valider empiriquement l’effet des méthodes de rêve sur la capacité et la stabilité du rappel dans le réseau de Hopfield classique ;
- visualiser et analyser l’influence du degré de la fonction dans les réseaux de Hopfield modernes sur la topologie du paysage énergétique et la robustesse au bruit.

3.2 Étude de l’augmentation de la capacité de stockage via le rêve dans le réseau classique

But de l’expérience. Afin d’analyser l’influence sur le stockage des deux méthodes de rêve décrites précédemment, nous mettons en place un protocole afin de mesurer combien de motifs enregistrés sont récupérables par le réseau.

Méthodes comparées :

- un réseau entraîné pour stocker P motifs, sans méthode de rêve
- un réseau entraîné avec l’unlearning pour augmenter ses capacités
- un réseau entraîné avec la méthode de la matrice projecteur

Protocole utilisé. Pour un nombre de motifs P fixé, on entraîne le réseau à stocker ces motifs. Ensuite, on applique ou non l’une des méthodes présentées plus tôt. Enfin, on initialise le réseau avec chacun des motifs d’entraînement, puis on le laisse converger.

Une fois la convergence atteinte, on compare l’état final obtenu au motif initial correspondant. En moyennant sur l’ensemble des motifs, on obtient un pourcentage d’erreur (motifs non récupérés correctement) en fonction du nombre de motifs P que l’on a tenté de stocker dans le réseau.

Ce protocole permet de tester la capacité effective du réseau et de déterminer jusqu’à combien de motifs peuvent être stockés sans que leur interférence ne devienne trop importante. Autrement dit, il mesure à partir de quelle charge certains motifs ne sont plus récupérables, alors même qu’ils sont fournis en entrée du réseau.

Hyperparamètres et dataset. Comme vu précédemment, certaines méthodes (unlearning et matrice projecteur) dépendent d’hyperparamètres. Ceux-ci ont été choisis à la fois pour obtenir de bons résultats et pour conserver un temps d’exécution raisonnable.

- **Unlearning** : 10 images aléatoires tirées en parallèle et un nombre d’itérations calculé à partir d’une formule définie dans [7], qui semblait la plus appropriée à ce cas.

- **Matrice projecteur** : 50 000 itérations afin de converger vers une matrice permettant de stocker suffisamment de motifs.

Le dataset utilisé est ImageNet 16×16 , avec une image par classe, convertie en binaire. Parmi ces 1 000 images (correspondant aux 1 000 classes), dans un premier cas nous avons conservé seulement les 256 premières et dans un second 256 images linéairement indépendantes, car la matrice projecteur ne fonctionne pas sans cette hypothèse. Le même protocole a également été appliqué à un dataset totalement décorré (images aléatoires).




FIGURE 3. Comparaison des protocoles (réseau classique, unlearning et matrice projecteur) sur trois configurations : ImageNet 16×16 , un sous-ensemble linéairement indépendant et un dataset non corrélé. Dans certains cas, l'expérience est arrêtée après la 100e image, puisque le réseau est déjà devenu instable.

Résultats et analyse. Cette section présente les résultats du protocole sur les trois jeux de données.

Pour $N=256$, les résultats théoriques (dans le cas de motifs aléatoires et décorrés) donnent une capacité typique d'environ $0.14N \simeq 35$ motifs pour le réseau classique, $0.58N \simeq 148$ motifs avec l'unlearning, et jusqu'à $N = 256$ motifs avec la matrice projecteur (si les motifs sont linéairement indépendants). On peut ainsi comparer ces ordres de grandeur aux résultats expérimentaux de la Fig. 3.

La première ligne (ImageNet 16×16) met en évidence l'impact des corrélations entre images et le fait que les patrons ne sont pas linéairement indépendants : la capacité observée reste très inférieure aux bornes théoriques. Cela s'explique par le comportement de la règle de Hebb en présence de motifs corrélés : elle ne garantit pas que chaque motif corresponde à un attracteur stable, et les interférences entre patrons favorisent l'apparition d'états parasites. Dans ce contexte, la matrice projecteur demeure la méthode la plus efficace. L'unlearning, quant à lui, ralentit la dégradation lorsque P augmente, mais n'améliore pas significativement le nombre de motifs récupérés sans erreur, qui reste ici d'environ 4.

Quand on se limite à un sous-ensemble linéairement indépendant, la matrice projecteur retrouve les résultats attendus (rappel correct jusqu'à $P \simeq N$). On voit aussi une amélioration pour l'unlearning, qui arrive à stocker environ 20 motifs. Ce n'est pas encore la limite théorique, mais on constate que l'indépendance linéaire réduit déjà une partie des interférences, même si les motifs restent corrélés.

Enfin, sur un dataset non corrélé (images aléatoires), l'unlearning atteint environ 150 motifs, ce qui correspond bien à $\approx 0.58N$. Le réseau classique, lui, plafonne autour de 20 motifs, ce qui est en dessous de $0.14N$. Cet écart peut venir du fait que N est petit et que notre critère de succès est strict (récupération exacte), ainsi que des détails du protocole de convergence.

3.3 Étude de l'influence de la modification de l'énergie dans les réseaux de Hopfield modernes

But de l'expérience. Cette partie vise à analyser expérimentalement l'effet de la fonction, utilisée pour définir l'énergie, sur le comportement des réseaux de Hopfield modernes. Nous cherchons en particulier à comprendre comment elle modifie la forme du paysage énergétique, la robustesse au bruit, ainsi que la dynamique de convergence. L'objectif est de visualiser ces effets et de relier les observations expérimentales aux intuitions théoriques (bassins plus raides, meilleure séparation entre motifs, réduction des états parasites).

Modèles comparés. Nous comparons :

- La fonction $F(x) = x^2$, équivalent au réseau classique;
- La fonction $F(x) = x^n$ pour chaque degré entre $n = 3$ et $n = 10$;
- La fonction $F(x) = e^{x/\sqrt{N}}$, qui correspond à une exponentielle régularisée.

Protocole utilisé. Deux expériences complémentaires sont menées.

- **Résistance au bruit :** On sélectionne une image stockée dans le réseau, puis on la bruitte en inversant un nombre k de pixels (passage de -1 à $+1$ ou inversement). Cette méthode garantit que exactement k pixels sont modifiés. Le bruit est limité à 128 pixels sur 256, car au-delà l'image devient plus proche de son négatif que de l'image originale, et dans un réseau de Hopfield classique (et souvent aussi dans les réseaux modernes), lorsqu'un motif est enregistré, son négatif peut également correspondre à un attracteur, ce qui rend l'interprétation des échecs ambiguë lorsque l'on dépasse ce seuil.

L'image bruitée est ensuite injectée comme état initial et le réseau converge selon une dynamique asynchrone. On compare l'état final à l'image d'origine (succès si récupération exacte). Le protocole est répété pour différents niveaux de bruit, différents motifs et différents nombres de motifs stockés P .

- **Analyse du profil énergétique :** On fixe un niveau de bruit (typiquement 100 pixels inversés) et on enregistre l'état et l'énergie du réseau à chaque mise à jour pendant la convergence. Une itération correspond à la mise à jour d'un neurone, soit environ 256 itérations pour un passage complet sur le réseau. On analyse ensuite l'énergie en fonction du temps et de la distance de Hamming de l'état par rapport au motif cible.

Hyperparamètres et dataset. Les expériences sont réalisées sur un dataset non corrélé (images aléatoires), afin d'isoler l'effet de la puissance. Dans le cas de l'analyse du profil énergétique, le nombre de motifs stockés est volontairement limité (par exemple à 5) afin de rester dans un régime où tous les modèles sont encore stables.

Résultats et analyse. L'expérience de résistance au bruit n'a été réalisée qu'avec trois réseaux différents :

- un réseau avec une fonction de la forme x^2 ;
- un réseau avec une fonction de la forme x^5 ;
- un réseau avec une fonction de la forme x^{10} .

Pour commencer, comme on peut l'observer sur la Fig. 4, pour le réseau avec une fonction de la forme x^2 , le nombre de motifs stockés varie de 0 à 50. Au-delà, cela n'a plus vraiment d'intérêt, principalement à cause de la capacité limitée du réseau. Dans la suite, on considère donc surtout les valeurs entre 0 et 25, qui correspondent à la zone de bon fonctionnement du modèle classique, comme on peut également l'observer sur la dernière ligne de la Fig. 3.

Pour les deux autres réseaux, on observe deux lignes noires qui délimitent la zone sur laquelle les mesures ont été effectuées. Au-delà, les valeurs affichées correspondent essentiellement aux bornes minimale et maximale. Cela est dû au temps de calcul, qui devenait trop important pour explorer tout l'espace des paramètres.




FIGURE 4. Comparaison du taux d'erreur en fonction du niveau de bruit et du nombre de motifs stockés, pour trois réseaux.

Dans tous les cas, et même pour le réseau classique dans sa zone de fonctionnement, on observe que tant que la capacité n'est pas saturée, le seuil maximal de bruit corrigible reste comparable entre les différentes puissances. En revanche, lorsque le nombre de motifs augmente, le réseau classique devient rapidement instable. On observe également une légère décroissance pour les réseaux modernes : pour le réseau en x^5 , on passe d'environ 100 à 90 pixels, et pour le réseau en x^{10} d'environ 100 à 92 pixels, ce qui reste légèrement supérieur au cas x^5 .

Ces résultats vont dans le sens des prédictions théoriques : lorsque l'on se rapproche de la saturation dans les réseaux modernes, la taille des bassins d'attraction tend à diminuer. Cependant, comme on le voit ici, les réseaux modernes restent nettement plus performants, car ils permettent de conserver une taille de bassin (ici le nombre de pixels bruitables) proche de celle du réseau classique, tout en autorisant le stockage d'un nombre bien plus élevé de motifs.

La Fig. 5 présente cette fois l'énergie normalisée (ce qui facilite la comparaison) en fonction (i) du nombre d'itérations de mise à jour du réseau et (ii) de la distance de Hamming au motif initial.

Cette figure correspond au second protocole : une image est bruitée en inversant 100 pixels, puis le réseau est laissé évoluer jusqu'à convergence. Les deux graphes permettent de visualiser la forme du paysage énergétique, qui dépend

Paysage énergétique des différents réseaux modernes




FIGURE 5. Comparaison du paysage énergétique des différents réseaux modernes en fonction polynomiale associée à l'énergie.

directement de la fonction d'énergie choisie (polynôme ou exponentielle). On retrouve cette forme à la fois dans l'évolution temporelle de l'énergie, et dans l'évolution de l'énergie en fonction de la distance de Hamming entre l'état courant et le motif original.

On observe aussi clairement l'effet de la puissance : pour une faible puissance, la diminution d'énergie vers le minimum est progressive. À l'inverse, pour des puissances plus élevées, on voit apparaître un **plateau** puis une **chute rapide** vers le minimum lorsque l'état devient suffisamment proche du motif. Dans nos résultats, cette chute se produit au plus tard lorsque l'on arrive autour de 30 pixels de différence.

Cette visualisation aide également à comprendre l'apparition des **états parasites**. Quand le réseau stocke beaucoup de motifs, les bassins d'attraction peuvent se chevaucher. Pour de faibles puissances (comme le modèle classique), les contributions énergétiques de plusieurs motifs peuvent s'additionner et créer des minima concurrents, parfois plus attractifs que les motifs mémorisés eux-mêmes, ce qui favorise les états parasites. À l'inverse, avec des puissances plus élevées, le plateau rend les bassins plus "sélectifs" : un motif voisin influence moins l'énergie tant qu'on n'est pas très proche, ce qui limite le chevauchement et permet de stocker davantage de motifs dans un réseau moderne.

En conclusion, cette visualisation permet de bien se rendre compte de l'effet du degré de la fonction polynomiale sur le paysage énergétique. On observe directement la forme attendue : pour les faibles puissances, la descente est plus progressive, alors que pour les fortes puissances on obtient un plateau suivi d'une chute rapide près du motif. Cela confirme donc les attentes théoriques de ce point de vue-là, et montre que les différences observées viennent principalement de la forme de la fonction d'énergie elle-même, qui rend les bassins plus sélectifs et limite le chevauchement (et donc les états parasites).

Enfin, la Fig. 6 permet de visualiser qu'il existe une trajectoire énergétique quasi unique : l'énergie d'un état est fortement liée à sa distance de Hamming au motif cible. Ici, on part d'une même image que l'on bruitte aléatoirement de 0 à 128 pixels, ce qui permet de retrouver les courbes précédentes, mais surtout




FIGURE 6. Évolution de l'énergie du réseau en partant d'un même motif avec un bruit croissant (0 à 128 pixels inversés). Chaque trajectoire correspond à une relaxation du réseau, ce qui permet de visualiser le paysage énergétique autour du motif attracteur. Comparaison entre un réseau quadratique (x^2 , équivalent au modèle classique) et un réseau moderne (x^{10}).

d'observer que les trajectoires se **superposent**. Elles se chevauchent presque parfaitement dans le cas de x^{10} , et restent en général très proches dans le cas du réseau classique.

Cela signifie que, lorsqu'un état se trouve dans le bassin d'attraction d'un motif mémorisé, son niveau d'énergie dépend presque uniquement de sa distance de Hamming à ce motif. La principale exception est le cas où l'état final est un état parasite, c'est-à-dire un point fixe influencé par plusieurs motifs stockés.

On voit aussi que certaines trajectoires n'atteignent pas le motif attendu. Dans le réseau classique, certaines trajectoires s'arrêtent à une distance intermédiaire, ce qui peut correspondre à une convergence vers un état parasite plutôt que vers un motif mémorisé. Dans d'autres cas, l'énergie finale est comparable mais la distance reste autour de 120 pixels : cela indique que le réseau a convergé vers un autre motif (très différent du motif cible), plutôt que de corriger le bruit.

3.4 Synthèse

Ainsi, nous avons pu observer précisément la forme des paysages énergétiques des réseaux modernes lorsque la puissance augmente, ainsi que l'évolution du réseau pendant sa relaxation. Nous confirmons également expérimentalement les tendances attendues pour les méthodes de rêve dans les réseaux classiques.

Ce que l'on peut surtout retenir, c'est que même si les réseaux classiques peuvent voir leur capacité augmenter grâce au rêve, les réseaux modernes permettent d'augmenter cette capacité beaucoup plus fortement (dans notre cas,

jusqu'à environ 19 fois), sans dégrader fortement la robustesse au bruit : le réseau corrige encore des perturbations importantes, avec un bassin d'attraction de l'ordre de 90 à 100 pixels inversés. Ces résultats montrent que les réseaux modernes apportent une réelle plus-value aux réseaux de Hopfield, en particulier lorsqu'on veut stocker un grand nombre de motifs.

4 Discussion

Nos résultats expérimentaux suggèrent le compromis classique entre capacité de stockage et taille des bassins d'attraction : l'augmentation de la puissance permet de stocker un nombre beaucoup plus élevé de motifs, tout en conservant une robustesse au bruit comparable tant que le réseau reste loin de la saturation. Lorsque l'on augmente fortement le nombre de motifs, on observe une légère diminution de la taille des bassins, ce qui va dans le sens des prédictions théoriques des réseaux de Hopfield modernes. Cependant, nos expériences ne permettent pas de vérifier ce point de manière exhaustive au voisinage de la saturation, car l'exploration de ce régime devient trop coûteuse en temps de calcul.

Il est important de souligner plusieurs limites de cette étude. Les expériences ont été menées principalement sur des données non corrélées (images aléatoires), ce qui constitue un cas favorable. Sur des données naturelles plus corrélées, comme des images réelles, les performances peuvent être moins bonnes, comme on l'a déjà observé avec les réseaux classiques. De plus, la taille du réseau reste modeste ($N = 256$), et le bruit appliqué est volontairement contrôlé (inversion exacte de pixels), ce qui ne reflète pas nécessairement tous les types de perturbations rencontrées en pratique. Enfin, comme nous n'avons qu'une taille précise de réseaux, on ne peut pas garantir que les tendances observées se généralisent parfaitement à toutes les valeurs de N .

Par ailleurs, le régime de capacité exponentielle n'a pas été exploré de manière exhaustive, notamment en raison des contraintes de calcul. Une étude plus systématique de ce régime permettrait de mieux caractériser le compromis capacité/bassin lorsque le nombre de motifs devient très grand.

Malgré ces limites, les résultats suggèrent que les réseaux de Hopfield modernes constituent une extension prometteuse du modèle classique, en particulier pour des applications nécessitant le stockage d'un grand nombre de motifs, tout en conservant une capacité de rappel robuste.

5 Conclusion

Nous avons présenté une revue détaillée (réseaux classiques, mécanismes de “rêve”, réseaux de Hopfield modernes), puis une étude expérimentale en deux volets : (i) l’impact des méthodes de rêve sur la capacité de stockage dans le réseau classique, et (ii) l’influence du degré du polynôme dans les réseaux de Hopfield modernes, et son impact sur la robustesse au bruit et la topologie du paysage énergétique. Nos expériences permettent à la fois de vérifier expérimentalement plusieurs résultats attendus théoriquement, et de visualiser concrètement les phénomènes discutés dans l’étude (capacité, bassins d’attraction, influence des corrélations, et apparition d’états parasites).

Nos résultats indiquent que les méthodes de rêve améliorent bien la capacité du modèle classique, mais que leurs performances restent fortement limitées lorsque les motifs sont corrélés. À l’inverse, l’augmentation du degré du polynôme de la fonction d’énergie dans les réseaux modernes impacte surtout la topologie du paysage énergétique (parois plus raides, sélection plus franche, réduction des états parasites) et permet de stocker beaucoup plus de motifs, tout en conservant une bonne robustesse au bruit tant que la capacité n’est pas saturée. Les perspectives principales sont l’étude systématique sur des motifs corrélés (images naturelles) et l’exploration plus poussée des régimes de forte charge, afin de mieux caractériser le compromis capacité/bassin.

Au-delà de leur rôle de mémoire associative, les réseaux de Hopfield modernes ouvrent aussi d’autres directions intéressantes. Ils peuvent notamment fournir une lecture énergétique de mécanismes proches de l’attention (par exemple en lien avec les architectures de type Transformers), où la dynamique peut être interprétée comme une minimisation d’énergie vers des états “compatibles” avec des clés/valeurs. Enfin, leur formulation en termes de paysage énergétique les rend également pertinents pour des approches de résolution de problèmes d’optimisation, où l’on cherche à construire une énergie dont les minima correspondent à des solutions.

Références

1. Amit, D.J., Gutfreund, H., Sompolinsky, H. : Storing infinite numbers of patterns in a spin-glass model of neural networks. *Physical Review Letters* **55**(14), 1530–1533 (1985). <https://doi.org/10.1103/PhysRevLett.55.1530>
2. Campagne, J.É. : éléments sur les réseaux de j. hopfield et les machines de boltzmann de g. hinton. HAL Open Science (2024), id : hal-04758703
3. Crick, F., Mitchison, G. : The function of dream sleep. *Nature* **304**(5922), 111–114 (1983). <https://doi.org/10.1038/304111a0>
4. Demircigil, M., Heusel, J., Löwe, M., Upgang, S., Vermet, F. : On a model of associative memory with huge storage capacity. *Journal of Statistical Physics* **168**, 288–299 (2017). <https://doi.org/10.1007/s10955-017-1806-y>
5. Hebb, D.O. : *The Organization of Behavior : A Neuropsychological Theory*. Wiley, New York (1949)
6. Hopfield, J.J. : Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the National Academy of Sciences* **79**(8), 2554–2558 (1982). <https://doi.org/10.1073/pnas.79.8.2554>
7. Hopfield, J.J., Feinstein, D.I., Palmer, R.G. : ‘unlearning’ has a stabilizing effect in collective memories. *Nature* **304**, 158–159 (1983). <https://doi.org/10.1038/304158a0>
8. Krotov, D., Hopfield, J.J. : Dense associative memory for pattern recognition. In : *Advances in Neural Information Processing Systems (NeurIPS)*. vol. 29 (2016). <https://doi.org/10.48550/arXiv.1606.01164>
9. Löwe, M. : On the storage capacity of hopfield models with correlated patterns. *The Annals of Applied Probability* **8**(4), 1216–1250 (1998). <https://doi.org/10.1214/aoap/1028903378>
10. Personnaz, L., Guyon, I., Dreyfus, G. : Information storage and retrieval in spin-glass like neural networks. *Journal de Physique Lettres* **46**(8), L-359–L-365 (1985). <https://doi.org/10.1051/jphyslet:01985004608035900>
11. Plakhov, A.Y., Semenov, S.A. : Neural networks : iterative unlearning algorithm converging to the projector rule matrix. *Journal de Physique I* **4**(2), 253–260 (1994). <https://doi.org/10.1051/jp1:1994105>
12. Velenik, Y. : *Le modèle d’ising*. Cours de DEA (2009)

Ressources

Code source du projet, contenant l’implémentation des réseaux de Hopfield et les expérimentations associées (GitHub) : <https://github.com/LubratJilian/PER-Hopfield-Networks>