
PER2025–023

Rêver pour mieux mémoriser :
optimisation mémoire dans les Recherche
réseaux de Hopfield



Redéfinir la topologie du paysage énergétique pour maximiser la robustesse et la capacité des réseaux de Hopfield

Etudiant : Jilian LUBRAT, IAID

Encadrant : Étienne LOZES

État de l'art :

1. Les réseaux de Hopfield Classiques

Introduits par John Hopfield en 1982 [1], ces réseaux proposent une architecture de mémoire associative adressable par le contenu (CAM). Contrairement à une mémoire classique (RAM) où l'accès se fait par adresse, cette architecture permet de retrouver une information complète à partir d'un fragment ou d'une version bruitée, mimant les capacités de reconstruction de la mémoire biologique.

1.1 Lien avec la physique statistique

L'innovation majeure de Hopfield réside dans l'analogie établie entre les réseaux de neurones et la physique statistique, spécifiquement les verres de spins. Ces derniers sont des alliages magnétiques comportant un petit nombre d'impuretés magnétiques disposées au hasard dans le métal. Les verres de spins peuvent être représentés par le Modèle d'Ising qui permet de décrire les interactions magnétiques des impuretés entre elles, et l'évolution de ces interactions [3]. Dans ce modèle, chaque impureté est assimilée à un « spin » pouvant prendre deux états discrets et peut influencer les autres impuretés.

Hopfield transpose ce fonctionnement aux réseaux de neurones en remplaçant les impuretés par les neurones, où les deux états modélisent l'activation ou le repos. Bien qu'il ait initialement formulé son modèle avec des neurones binaires $\{0,1\}$, il est courant dans la littérature [2, 4, 7] d'utiliser le formalisme d'Ising pour les valeurs que peuvent prendre les neurones, soit $\{-1,1\}$. Cela ne change pas les résultats ni les équations, c'est donc ce formalisme que nous utiliserons.

Structurellement, le réseau forme un graphe complet non orienté, comme illustré en Figure 1. Dans cette configuration, chaque neurone est connecté à tous les autres, sauf lui-même via des connexions synaptiques symétriques. Le système est entièrement défini par un état initial des neurones et une matrice de poids symétrique à diagonale nulle.




Figure 1 : Architecture d'un réseau de Hopfield à 5 neurones. Représenté sous forme de graphe complet non orienté, illustrant l'interconnexion totale entre les neurones. Il n'y a pas d'interconnexion des neurones avec eux même. Les états binaires sont encodés par la couleur des nœuds : -1 (blanc) et +1 (noir).

1.2 Dynamique de Relaxation et Paysage Énergétique

Pour définir rigoureusement le fonctionnement du réseau, nous adopterons les notations suivantes :

- N : le nombre de réseau de neurones
- $X \in \{-1, 1\}^N$: le vecteur d'état du réseau à un instant t , où X_i représente l'état du neurone i .
- $W \in \mathbb{R}^{N \times N}$: la matrice des poids synaptiques, où W_{ij} est les poids de la connexion entre le neurone j et le neurone i .
- $\{\xi^1, \xi^2, \dots, \xi^P\}$: l'ensemble des P patterns avec ξ un pattern de taille N

Le fonctionnement du réseau est un processus de recherche d'un état stable, basé sur la dynamique suivante [1]:

- On initialise le réseau dans un état quelconque X (par exemple une version bruitée d'une information mémorisée)
- On laisse le système évoluer librement, les neurones vont interagir pour minimiser les frustrations locales et guider le système vers un état stable.

Durant cette évolution du système l'état du neurone i est mis à jour en suivant la règle :

$$X_i(t + 1) = \rho \left(\sum_{j \neq i} W_{ij} X_j(t) \right)$$

Avec ρ une fonction d'activation, en l'état $\text{sign}()$ pour respecter le modèle d'Ising.

Pour ce qui est de l'évolution du système, on peut distinguer deux catégories [4] :

- Évolution Synchrones : Tous les neurones sont mis à jour simultanément en fonction de l'état du réseau à l'instant t . Bien que parallélisable, cette dynamique peut ne pas converger vers un état stable en engendrant des oscillations cycliques entre deux états différents.
- Évolution asynchrone : Un seul neurone est sélectionné (aléatoirement ou séquentiellement) pour être mis à jour à chaque pas de temps. C'est ce mode qui garantit la convergence vers un état stable dans le modèle de Hopfield original [1].

Du fait de l'analogie avec le système des verres de spin de la physique statistique apportée par Hopfield, on peut assimiler l'évolution du réseau à la relaxation d'un système physique vers un état de minimum local d'énergie. Cette fonction d'énergie ou fonction de Lyapunov est définie comme étant [1] :

$$E = -\frac{1}{2} \sum_{i,j} W_{ij} X_i X_j$$

Les états stables du réseau sont ainsi des minimums locaux ou globaux de l'énergie du système. La figure 2 montre un exemple de paysage énergétique d'un réseau de Hopfield ayant mémorisé un motif, on y observe comment le système peut converger vers un état stable à partir un état initial donné.

Dans ce contexte, l'apprentissage revient à sculpter le paysage énergétique. Cela est fait en ajustant les poids synaptiques via la règle de Hebb, proposé par Donald Hebb en 1949, et qui postule le renforcement de la connexion entre deux neurones lors d'une activation simultanée [5]. Dans le cadre des réseaux de Hopfield, pour stocker P motifs, elle s'écrit :

$$W_{ij} = \frac{1}{N} \sum_{p=1}^P X_i^{(p)} X_j^{(p)} \quad \text{avec } W_{ii} = 0$$

On cherche donc à positionner les minima locaux (les "creux" du paysage) aux coordonnées exactes des motifs à mémoriser. Le processus de rappel de mémoire correspond alors physiquement à la "descente" d'une bille le long de ce paysage jusqu'au fond du bassin d'attraction le plus proche [1].




Figure 2 : Représentation du paysage énergétique du réseau de la figure 1. On distingue un minimum global (en bleu), représentant un pattern mémorisé, et un minimum local (en vert), illustrant un état parasite issu des interférences entre les souvenirs.

1.3 Limites des réseaux de Hopfield

Il a été démontré théoriquement par Daniel J. Amit, Hanoch Gutfreund et H. Sompolinsky [2], que les réseaux de Hopfield ont une limite de stockage du nombre de patterns qui est d'environ $0.14 N$. Cette limite avait été observée empiriquement par Hopfield lui-même dès 1982 [1].

Plus précisément, si l'on définit le paramètre de charge α comme le ratio entre le nombre de motifs stockés P et le nombre de neurones N :

$$\alpha = \frac{P}{N}$$

Cela sous-entend que la capacité de stockage augmente linéairement avec N . Pour aller plus loin, l'analyse thermodynamique réalisée par Daniel J. Amit, Hanoch Gutfreund et H. Sompolinsky a défini trois phases distinctes :

- Si $\alpha < 0.05$, alors les patterns stockés correspondent parfaitement aux minima globaux de la fonction d'énergie. Le rappel est quasi-parfait.
- Dans le cas $0.05 < \alpha < 0.14$, le réseau fonctionne encore, mais il peut apparaître des états parasites qui sont des combinaisons linéaires des informations enregistrées.
- Au-delà $\alpha > 0.14$, le nombre d'états parasites devient trop grand et le paysage énergétique devient chaotique, rendant toute mémorisation impossible.

De plus, cette limite théorique suppose que les motifs stockés soient décorrélés (orthogonaux). Dans un cas réaliste, les patterns présentent souvent des corrélations (images similaires), donc l'interférence entre les souvenirs augmente. Cela provoque l'apparition d'états parasites (dont un exemple est illustré par le point vert sur la figure 2) et entraîne un effondrement de la capacité de stockage bien en dessous de 0.14 fois le nombre de neurones.

Ce phénomène a été formellement démontré par Personnaz, Guyon et Dreyfus (1985) ainsi que par Löwe (1998), qui ont établi que la règle de Hebb classique ne permet pas de garantir la stabilité des patterns lorsqu'ils sont corrélés [6,7]. C'est-à-dire que les patterns d'entraînements ne sont pas des minimum locaux ou globaux de la fonction d'énergie et donc ne représentent pas un état stable.

2. Le rêves dans les réseaux de Hopfield Classiques

Une des limitations majeures des réseaux de Hopfield classiques réside dans leur faible capacité de stockage. Pour y remédier, plusieurs méthodes ont été proposées afin d'optimiser cette capacité tout en conservant la dynamique fondamentale du réseau.

2.1 L'unlearning

Le mécanisme d'unlearning (désapprentissage) a été introduit dans ce contexte par Hopfield, Feinstein et Palmer [8]. Ils s'inspirent des travaux de Crick et Mitchison (1983) sur le sommeil paradoxal, qui postulent que les rêves servent à éliminer les connexions parasites accumulées durant la journée [9]. Ce mécanisme de nettoyage est transposé mathématiquement au réseau de Hopfield.

L'analogie est la suivante : si la règle de Hebb standard permet de stocker des motifs en "creusant" des bassins d'attraction dans le paysage énergétique, l'unlearning agit à l'inverse. En appliquant une règle anti-Hebbienne, il permet de "lisser" le paysage en réduisant la profondeur des minima locaux indésirables.

Le processus algorithmique est le suivant :

- Un état initial aléatoire est généré.
- On laisse le réseau converger librement depuis cet état jusqu'à atteindre un état stable.
- On applique la règle de Hebb de manière négative, pondérée par un taux d'apprentissage ϵ (epsilon) très faible, sur l'état obtenu : $W_{ij} = W_{ij} - \epsilon X_i X_j$
- Ce processus est itéré plusieurs fois.

Cette méthode repose sur une propriété statistique du paysage énergétique : lorsque la charge du réseau est élevée, les états parasites deviennent extrêmement nombreux, bien plus que les motifs mémorisés. En partant d'un bruit aléatoire, le réseau a donc statistiquement beaucoup plus de chances de converger vers l'un de ces multiples états parasites plutôt que vers un souvenir appris. L'application de la règle inverse sur le point de convergence permet ainsi de pénaliser spécifiquement ces états erronés, sans affecter significativement les souvenirs réels car ils sont statistiquement moins souvent visités par hasard [8].

Cependant, les hyperparamètres optimaux (la valeur de ϵ et le nombre d'itérations) ne sont pas définis analytiquement de manière unique. Hopfield, Feinstein et Palmer [8] recommandent une valeur ϵ faible (typiquement $0.01 < \epsilon < 0.1$) et soulignent que le nombre d'itérations ne doit pas être excessif, au risque d'éroder les souvenirs légitimes et de détruire le paysage énergétique utile.

Cette méthode permet expérimentalement d'augmenter la capacité de stockage du réseau jusqu'à 0,58 fois le nombre de neurones, soit environ quatre fois plus que la capacité de base. Ce gain significatif n'est toutefois garanti que sous l'hypothèse de motifs décorrélés. Si les données sont fortement corrélées, l'efficacité du désapprentissage diminue, nécessitant des itérations supplémentaires ou des règles de projection plus complexes.

2.2 La matrice projecteur

Une autre méthode fondamentale est celle de la Matrice Projecteur (ou règle de la Pseudo-Inverse). Ici, les réseaux de Hopfield sont abordés sous un angle purement algébrique : l'ensemble des motifs d'entraînement est vu comme une base vectorielle pas nécessairement orthogonale.

L'objectif est de projeter tout état initial placé en entrée du réseau vers le sous-espace engendré par les motifs mémorisés, sous-espace dans lequel les motifs mémorisés sont orthogonaux entre eux. En 1985, Personnaz, Guyon et Dreyfus [6] ont démontré que la règle de Hebb classique échouait pour des motifs corrélés et ont proposé de calculer directement la matrice de poids comme un projecteur orthogonal :

$$W = A(A^T A)^{-1} A^T$$

Où A est une matrice dont les colonnes sont les motifs d'entraînement. Cette méthode garantit que tous les motifs, même corrélés, sont des points fixes parfaits, tant qu'ils sont linéairement indépendants.

Cependant, le calcul direct de cet inverse est coûteux et peu interprétable biologiquement. C'est ici que le lien avec le rêve réapparaît. Plakhov et Semenov (1994) [10] ont démontré qu'une procédure itérative, assimilable au mécanisme de rêve, permettait de transformer progressivement la matrice de Hebb en cette matrice projecteur.

Le processus algorithmique est le suivant [10] :

- On crée la matrice de poids classique du réseau avec la règle de Hebb mais on conserve les valeurs de la diagonale
- On initialise le réseau avec un motif aléatoire X
- On calcule les champs locaux via :

$$h_i = \sum_{j=1}^N W_{ij} X_j$$

- On modifie W via le calcul suivant :

$$W_{ij} = W_{ij} - \frac{\epsilon}{N} h_i h_j$$

- On itère plusieurs fois

Il a été démontré que lorsque le nombre d'itérations tend vers l'infini, la matrice W converge asymptotiquement vers la matrice des projecteurs [10]. Pour garantir cette convergence, le taux d'apprentissage ϵ doit être inférieur à une valeur critique :

$$\epsilon < \frac{1}{\lambda_{\max}}$$

Où $\lambda_{\max}$ est la valeur propre maximale de la matrice de poids initiale du réseau.

Cette approche permet de s'affranchir de la contrainte d'orthogonalité : les motifs n'ont pas besoin d'être décorrélés, mais ils doivent être linéairement indépendants. Si des motifs sont linéairement dépendants, ils formeront un état parasite. De plus, cette méthode permet de stocker au maximum N patterns linéairement indépendants. Au-delà, l'espace est saturé : la matrice converge vers la matrice identité. Dans ce cas extrême, tout état d'entrée devient stable le réseau n'apprend plus rien, et le système est considéré comme dégénéré.

3. Les réseaux de Hopfield Moderne

Les réseaux de Hopfield modernes ont pour objectif d'augmenter drastiquement la capacité de stockage par rapport aux réseaux classiques. Nous avons vu précédemment que la limite théorique des réseaux de Hopfield standards était d'environ 0.14 fois le nombre de neurones et pouvait être augmentée jusqu'au nombre de neurones en utilisant la règle de la matrice de projection.

3.1 Définition moderne des réseaux de Hopfield

Krotov et Hopfield (2016) [11] ont démontré qu'il était possible de dépasser ces limites en introduisant les mémoires associatives denses. L'intuition physique derrière cette approche repose sur l'analyse du paysage énergétique, dans le modèle classique, les puits d'attraction (les minima locaux et globaux) sont trop larges, ce qui favorise l'apparition d'états parasites constitués de mélanges de plusieurs motifs d'entraînement.

L'idée est donc de modifier la topologie du paysage énergétique pour rendre ces puits plus étroits et plus profonds autour des motifs mémorisés.

Pour cela, ils proposent de redéfinir la fonction d'énergie globale du système par [11] :

$$E = - \sum_{\mu=1}^P \sum_i^N F(\xi_i^\mu X_i)$$

Où F est une fonction de lissage. Cette fonction peut prendre une forme polynomiale x^n comme proposé par Hopfield et Krotov [11] ou exponentielle e^x comme proposé par Demircigil et al. [12]. De cette nouvelle définition de l'énergie, on dérive la règle de mise à jour suivante :

$$X_i^{(t+1)} = \text{Sign} \left[\sum_{\mu=1}^P \left(F \left(\xi_i^\mu + \sum_{j \neq i} \xi_i^\mu X_j^{(t)} \right) - F \left(-\xi_i^\mu + \sum_{j \neq i} \xi_i^\mu X_j^{(t)} \right) \right) \right]$$

Contrairement aux modèles précédents basés uniquement sur les champs magnétiques induits, la règle de mise à jour ici est explicitement pilotée par la différence d'énergie. Concrètement, l'argument de la fonction signe correspond à la différence d'énergie entre l'état où le neurone est actif (+1) et l'état où il est inactif (-1), le reste du réseau étant figé. Le système met ainsi à jour chaque unité de manière à garantir la minimisation de l'énergie globale de la configuration.

Il est intéressant de noter que le réseau de Hopfield classique est un cas particulier de ce modèle. En effet, si l'on choisit la fonction $F(x) = x^2$, on retrouve les équations standard en remplaçant la matrice de poids par son expression non normalisée par le nombre de neurones. Ces réseaux modernes généralisent donc le fonctionnement global des réseaux classiques tout en offrant une flexibilité nouvelle grâce au choix de la fonction.

3.2 Amélioration de la capacité de stockage

Ce changement permet d'obtenir une capacité de stockage bien supérieure, qui dépend directement de la puissance de la fonction. On peut déterminer la limite supérieure du nombre de motifs stockables, pour une fonction polynomiale de degré, cette capacité suit la loi :

$$P_{max} \approx \alpha_n N^{n-1}$$

Où α_n est une constante qui dépend de la puissance de la fonction utilisée. Pour $n = 2$ on retrouve $\alpha_n = 0.14$, et α_n diminue de manière linéaire alors que N^{n-1} augmente de manière exponentielle quand n augmente ce qui permet de justifier que la capacité P_{max} augmente [11].

Avec le remplacement de la fonction d'interaction par une exponentielle, tel que proposé par Demircigil et al., la capacité de stockage peut être étendue bien au-delà des limites polynomiales. Elle devient exponentielle par rapport au nombre de neurones, et est donnée par :

$$P_{max} \approx 2^{\frac{N}{2}}$$

Cependant, bien que la capacité augmente considérablement, elle s'accompagne d'une contrepartie majeure concernant la capacité d'attraction des motifs mémorisés. En effet, la taille des bassins d'attraction de chaque motif mémorisé diminue fortement. Concrètement, la capacité du réseau à corriger les erreurs, c'est-à-dire à converger vers le bon motif à partir d'une entrée bruitée, se réduit à mesure que le nombre de motifs stockés augmente. Dans le régime où le nombre de motifs stockés est exponentiel, le rayon du bassin d'attraction tend vers 0 [4].

4. Les Réseaux de Hopfield Continus et l'Attention

Il a été établi en 2021 par Ramsauer et al. [13] qu'il existe une équivalence formelle entre la minimisation de l'énergie d'un réseau de Hopfield et la couche d'attention des Transformers, l'architecture pilier des LLM actuels. Cette découverte a ouvert la voie à une interprétation énergétique des mécanismes d'attention.

4.1 Les réseaux continus

Pour exploiter ce lien dans des architectures d'apprentissage profond, la différentiabilité est indispensable. Cela pose un problème pour les réseaux de Hopfield classiques qui, reposant sur le modèle d'Ising, sont par nature discrets : les neurones ne peuvent prendre que deux valeurs (+1 et -1), rendant impossible le calcul de gradients nécessaires à la rétropropagation.

Il est important de noter que cette question de la continuité avait déjà été traitée par J.J. Hopfield lui-même dès 1984 [14]. Il avait alors démontré que les neurones à réponse continue conservaient les propriétés de stabilité des réseaux binaires, l'état du réseau étant défini par une équation différentielle non linéaire en fonction du temps.

Toutefois, l'approche moderne nécessite des adaptations significatives par rapport aux travaux historiques de Hopfield. En effet, les réseaux de Hopfield doivent posséder une capacité de stockage exponentielle pour être pertinents dans le contexte de l'apprentissage profond. Ramsauer et al. ont donc formulé une nouvelle fonction d'énergie spécifique, en se basant sur celle des réseaux modernes avec une fonction $F(x) = e^x$ proposée par Demircigil et al.

Or, sans contrainte supplémentaire, cette énergie peut tendre vers $-\infty$, ce qui empêcherait la convergence du système vers un état stable bien défini. Pour résoudre ce problème, ils vont modifier la fonction d'énergie et introduire un terme de régularisation quadratique obligeant le système à sélectionner une valeur finie. La nouvelle fonction d'énergie s'écrit alors [13] :

$$E = - \sum_{\mu=1}^P \sum_i^N e^{\xi_i^{\mu} x_i} \Rightarrow E = - \sum_{\mu=1}^P \log \left(\sum_i^N e^{\xi_i^{\mu} x_i} - \frac{1}{2} \xi^T \xi + c \right)$$

4.2 Les réseaux de Hopfield et les couches d'attention

Cette modification a permis de faire émerger naturellement la règle de mise à jour softmax caractéristique du mécanisme d'attention, là où l'approche historique de 1984 ne le permettait pas directement. Cette équivalence mathématique établit ainsi un pont fondamental entre les réseaux de neurones récurrents inspirés de la physique statistique et les architectures modernes basées sur l'attention [13].

Ce lien formel entre les réseaux de Hopfield et les couches d'attention des Transformers permet, dans un premier temps, de modéliser ces dernières comme des mémoires associatives. Cela offre une nouvelle grille de lecture pour comprendre le mécanisme d'Attention à travers le prisme de la minimisation d'énergie, un processus bien documenté en physique statistique.

Cependant, l'apport de Ramsauer et al. [13] ne se limite pas à la théorie. Ils proposent concrètement d'intégrer de véritables couches de Hopfield au sein des architectures profondes. Contrairement à l'attention classique qui s'exécute en une seule passe, ces couches permettent d'effectuer plusieurs cycles de mise à jour avant de transmettre l'information à la couche suivante. D'après leur étude, cette capacité de raffinement itératif s'avère particulièrement utile pour les applications nécessitant une forte capacité de mémoire de travail, comme en biologie computationnelle ou en chimie.

5. L'application des réseaux de Hopfield continus aux problèmes d'optimisation

Au-delà de leur fonction de mémoire associative ou de leur lien récent avec les mécanismes d'attention, les réseaux de Hopfield offrent une méthode puissante pour aborder des problèmes d'optimisation. En particulier, tout comme pour les Transformers, ce sont ici les réseaux de Hopfield continus qui sont utilisés.

Dans leur article de référence "*Neural Computation of Decisions in Optimization Problems*" (1985), J.J. Hopfield et D.W. Tank [15] ont démontré que la dynamique naturelle du réseau, qui cherche à minimiser son énergie, pouvait être utilisée pour trouver une solution approchée à un problème donné.

Le principe est le suivant : il s'agit de modéliser le problème d'optimisation de telle sorte que ses contraintes et sa fonction de coût soient encodées directement dans la fonction d'énergie du réseau.

$$E_{totale} = R_{contraintes} + E_{coût}$$

Ainsi, lorsque le réseau converge vers un état stable, cet état correspond à une solution valide et optimisée du problème. Une fois la fonction d'énergie du système obtenue, on peut définir les règles que doit respecter la matrice de poids W et ainsi la calculer.

Pour illustrer cette capacité, Hopfield et Tank ont appliqué leur modèle au célèbre problème du Voyageur de Commerce (TSP), qui consiste à trouver le chemin le plus court passant par N villes une seule fois avant de revenir au point de départ. Pour ce faire [15], ils ont utilisé une matrice de neurones de taille $N \times N$ où les lignes représentent les villes et les colonnes l'ordre de passage. La difficulté réside alors dans la définition de la fonction d'énergie, qui doit combiner deux types de termes contradictoires :

- Les termes de contraintes : Ils pénalisent les configurations invalides (par exemple, si le réseau propose de visiter deux villes simultanément ou de visiter la même ville deux fois). Si ces règles sont violées, l'énergie augmente drastiquement.
- Le terme de coût : Il représente la distance totale parcourue. Le réseau cherche à minimiser ce terme en choisissant des connexions entre villes proches.

Une fois cela fait, la matrice de poids est définie et le réseau est lancé depuis un état initial aléatoire en espérant converger vers un minimum global afin d'avoir la solution optimale.

Il convient toutefois de nuancer l'efficacité de cette approche. Contrairement à ce que l'on pourrait espérer, le réseau de Hopfield ne converge pas nécessairement vers le minimum global qui est la solution optimale, mais tend à se stabiliser dans un minimum local profond. Comme le notent Hopfield et Tank [14], le réseau fournit une solution suffisamment bonne très rapidement, fonctionnant comme une heuristique analogique efficace plutôt que comme un algorithme exact.

Bibliographie :

- [1] J. J. Hopfield, "Neural networks and physical systems with emergent collective computational abilities," *Proceedings of the National Academy of Sciences*, vol. 79, no. 8, pp. 2554–2558, 1982. doi: 10.1073/pnas.79.8.2554
- [2] D. J. Amit, H. Gutfreund, et H. Sompolinsky, "Storing Infinite Numbers of Patterns in a Spin-Glass Model of Neural Networks," *Physical Review Letters*, vol. 55, no. 14, pp. 1530–1533, 1985. doi: 10.1103/PhysRevLett.55.1530
- [3] Y. Velenik, "Le modèle d'Ising," *Cours de DEA*, fév. 2009. [En ligne]. Disponible : <https://cel.hal.science/cel-00392289>
- [4] J.-E. Campagne, "Éléments sur les réseaux de J. Hopfield et les Machines de Boltzmann de G. Hinton," *HAL Open Science*, Id: hal-04758703, 2024. [En ligne]. Disponible : <https://hal.science/hal-04758703v1/file/main.pdf>
- [5] D. O. Hebb, *The Organization of Behavior: A Neuropsychological Theory*. New York: Wiley, 1949.
- [6] L. Personnaz, I. Guyon, et G. Dreyfus, "Information Storage and Retrieval in Spin-Glass like Neural Networks," *Journal de Physique Lettres*, vol. 46, no. 8, pp. L-359–L-365, 1985. doi: 10.1051/jphyslet:01985004608035900
- [7] M. Löwe, "On the storage capacity of Hopfield models with correlated patterns," *The Annals of Applied Probability*, vol. 8, no. 4, pp. 1216–1250, 1998. doi: 10.1214/aoap/1028903378
- [8] J. J. Hopfield, D. I. Feinstein, et R. G. Palmer, "'Unlearning' has a stabilizing effect in collective memories," *Nature*, vol. 304, pp. 158–159, 1983. doi: 10.1038/304158a0
- [9] F. Crick et G. Mitchison, "The function of dream sleep," *Nature*, vol. 304, no. 5922, pp. 111–114, 1983. doi: 10.1038/304111a0
- [10] A. Y. Plakhov et S. A. Semenov, "Neural networks: iterative unlearning algorithm converging to the projector rule matrix," *Journal de Physique I*, vol. 4, no. 2, pp. 253–260, fév. 1994. doi: 10.1051/jp1:1994105
- [11] D. Krotov et J. J. Hopfield, "Dense Associative Memory for Pattern Recognition," in *Advances in Neural Information Processing Systems (NIPS)*, vol. 29, 2016. doi: 10.48550/arXiv.1606.01164
- [12] M. Demircigil, J. Heusel, M. Löwe, S. Ugang, et F. Vermet, "On a Model of Associative Memory with Huge Storage Capacity," *Journal of Statistical Physics*, vol. 168, pp. 288–299, 2017. doi: 10.1007/s10955-017-1806-y
- [13] H. Ramsauer *et al.*, "Hopfield Networks is All You Need," in *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021. doi: 10.48550/arXiv.2008.02217
- [14] J. J. Hopfield, "Neurons with graded response have collective computational properties like those of two-state neurons," *Proceedings of the National Academy of Sciences*, vol. 81, no. 10, pp. 3088–3092, 1984. doi: 10.1073/pnas.81.10.3088
- [15] J. J. Hopfield et D. W. Tank, "Neural Computation of Decisions in Optimization Problems," *Biological Cybernetics*, vol. 52, pp. 141–152, 1985. doi: 10.1007/BF00339943